

myoArm Forward-State-Estimation 研究遂行テキスト

理系大学院生が Project 1 を理解し、再現し、次フェーズへ拡張するために

作成日: 2026-05-12 / 対象: 修士・博士前期～博士後期初期 / Repository: myoarm-forward-state-estimation

このテキストの目的

この資料は、myoArm forward-state-estimation 研究を「読む」だけでなく、実際に再現し、結果を検証し、次の Project 2 / Project 3 に発展させるための作業教科書である。読者は Python / PyTorch / 基礎的な制御・確率の知識を持つ理系大学院生を想定する。

外部画像は使わず、リポジトリ内の生成図表と既存 primer 画像のみを用いる。

目次

1. 研究の全体像	2
1.1. 研究群の中での位置づけ	2
1.2. 中心問い	3
1.3. この資料の読み方	4
1.4. なぜ closed-loop pipeline を考えるのか	4
1.5. このループは妥当なのか	5
1.6. Downstream policy の 3 分類	5
1.7. Closed-loop pipeline を時刻順に読む	6
1.8. 1 step の擬似コード	6
1.9. delay がない場合とある場合	7
1.10. correction gain K の直感	7
1.11. logger に全層を保存する理由	8
2. 必要な前提知識	8
2.1. 筋骨格 reaching と MyoSuite	8
2.2. 信号名の区別	9
2.3. 状態ベクトル	9
3. Forward model	10
3.1. なぜ forward model が必要か	10
3.2. 残差 MLP	10
3.3. one-step と multi-step supervision	10
4. Predictive state observer	11
4.1. 基本式	11
4.2. fixed-lag delay handling	11
4.3. 二層 reliability-adaptive observer	12
4.3.1. 二層の役割と時間スケール	12
4.3.1.1. Step-wise signal flow (within-trial)	12
4.3.1.2. Iteration-wise signal flow (across-trial)	12
4.3.1.3. 二層の関係	13
4.3.1.4. なぜ二層に分けるか	13
4.3.2. Within-trial layer: innovation history から reliability へ	13
4.3.2.1. EMA(Exponential Moving Average / 指数移動平均)とは	14
4.3.2.2. Simple Moving Average との対比	14
4.3.2.3. Project 1 での具体的使用	14
4.3.2.4. 動作例((none, d=18) cell, qvel field)	15

4.3.2.5. 生物学的解釈	15
5. EMA 形式と等価。 $\alpha = \Delta \frac{t}{\tau}$ 、つまり EMA の α は神経 leaky integrator の time constant τ の逆数に 対応する。	15
5.0.1. Across-trial layer: SPSA outcome adaptation	16
5.0.2. oracle-supervised predictor: upper bound diagnostic (Appendix C 教材)	16
6. 実験 pipeline	17
6.1. Repository の構造	17
6.2. 最小再現手順	17
6.3. 実験 command の読み方	17
7. 主要結果の読み方	18
7.1. C1: default reliability is task-misaligned	18
7.2. C2: single-cell SPSA closes most of the gap	19
7.3. C3: multi-cell SPSA reveals parameterisation ceiling	20
7.4. C4: task transfer reveals task-dependent rule	21
8. 研究者としての作業手順	21
8.1. 1 日の作業サイクル	21
8.2. 実験前チェックリスト	21
8.3. 結果解釈チェックリスト	22
9. よくある失敗と対処	22
9.1. target が paired でない	22
9.2. K と H の混同	22
9.3. behaviour-cloned policy の open-loop 化(Appendix C 教材)	22
9.4. endpoint-error policy を optimal controller と呼ぶ	22
9.5. SPSA outcome を training-time と deployed eval で混同する	23
9.6. oracle なしを “no oracle access” と書く	23
10. Project 2 / Project 3 への接続	23
10.1. Project 1.5: context-conditioned β network	23
10.2. Project 2: Bayesian integration	23
10.3. Project 3: cortico-cerebellar loop	24
11. 演習	24
11.1. 演習 1: 状態 schema を確認する	24
11.2. 演習 2: test を通す	24
11.3. 演習 3: 図表を読み解く	24
11.4. 演習 4: 新しい transfer test を設計する	25
11.5. 演習 5: context-conditioned β の prototype を設計する	25
12. 参考資料	25
12.1. Repository 内	25
12.2. Obsidian 内	25
12.3. 文献	26
13. 最後に	26

1. 研究の全体像

1.1. 研究群の中での位置づけ

本研究は myoArm 新規研究群の Project 1 である。旧 myoarm-lambda-ep の lambda-EP 単独路線から離れ、重力下の筋骨格 reaching における forward prediction、遅延感覚 feedback、不確実性統合を検証する流れの最初の本体プロジェクトである。

Project	中心問い	Project 1 との関係
---------	------	----------------

Project 0	共通 myoArm 基盤	target set、logger、noise/delay wrapper、metrics を提供
Project 1	forward model + predictive state observer	本資料の対象
Project 2	Bayesian reliability-weighted integration	視覚・固有受容・prediction・prior の信頼度統合へ拡張
Project 3	cortico-cerebellar loop	residual MLP forward model を cerebellar-like module に置換
Project 4	cortical population dynamics	M1-like population dynamics へ拡張

研究ノート

Project 1 は「完成した単独テーマ」であると同時に、後続 Project の土台である。したがって、実装では再利用可能な状態表現・logger・評価 pipeline を作ることが重要になる。

1.2. 中心問い

Project 1 の中心問いは次である。

中心問い

myoArm reaching において、forward-model-based predictive state observer は、agent 自身が online で生成できるシグナル(innovation history と per-episode reaching outcome)だけから、correction gain を self-adapt できるか。

神経科学的には、これは小脳 forward model、efference copy、遅延感覚 feedback、sensory prediction error の追跡、感覚信頼度の online 推定、そして reaching outcome に基づく試行間学習を、筋骨格腕シミュレーション上で検証する第一段階である。生体は per-condition の swept oracle(K^* ラベル)を持たないので、agent-available signal だけで correction gain が決まりうるかは、forward-model framework の生物学的妥当性を問う中心的な実験となる。

工学的には、これは以下の問題になる。

```

前の推定状態  $\hat{x}_t$  と、前に出した運動指令  $u_t$ 
-> forward model
-> 次時刻の予測状態  $\hat{x}_{pred}(t+1)$ 

遅延・ノイズ付き観測  $y_{t+1}$ 
-> sensory prediction-error correction
-> 更新後の推定状態  $\hat{x}_{t+1}$ 

 $\hat{x}_{t+1}$ 
-> controller
-> 次の運動指令  $u_{t+1}$ 
-> muscle excitation
-> myoArm plant

```

つまり、同じ $\hat{x}$ でも「更新前」と「更新後」がある。混乱を避けるため、本資料では 1 step の流れを $\hat{x}_t \rightarrow \hat{x}_{pred}(t+1) \rightarrow \hat{x}_{t+1} \rightarrow u_{t+1}$ と読む。

ここで $\hat{x}_{pred}$ と $\hat{x}$ は役割が違う。

記号	意味	どう作るか
$\hat{x}_{pred}(t+1)$	forward model だけで作った「次はこうなっているはず」という予測状態	$\hat{x}_t$ と u_t を forward model に入れる

$\hat{x}_{t+1}$	観測も使って補正した「controller に渡す最終的な推定状態」	$\hat{x}_{t+1}$ と delayed/noisy observation y_{t+1} の差分を correction gain K で補正する
-----------------	------------------------------------	--

直感

$\hat{x}_{pred}$ は「自分のモデルだけでの予想」。

$\hat{x}_{hat}$ は「予想に、届いた感覚情報を加味して更新した現在の信念」。

controller が使うのは $\hat{x}_{pred}$ ではなく、基本的には更新後の $\hat{x}_{hat}$ である。

1.3. この資料の読み方

この資料は、最初から C1-C4 の論文主張を読む構成にはしていない。まず closed-loop pipeline、状態表現、forward model、predictive state observer、そして二層適応則(within-trial reliability と across-trial outcome adaptation)の意味を理解し、その後で結果 C1-C4 を読む。

推奨順序:

1. closed-loop pipeline が何のためにあるか
2. $\hat{x}_{hat}$ / $\hat{x}_{pred}$ / observation / action の違い
3. forward model が何を予測するか
4. sensory prediction-error correction と gain K の意味
5. innovation history からの within-trial reliability
6. SPSA across-trial outcome adaptation
7. oracle-supervised upper bound (Appendix 教材)
8. C1-C4 の結果

oracle-supervised predictor(旧 §3.4)は upper-bound diagnostic として Appendix C 化された。Project 1 の中心提案は、oracle ラベルを使わない二層適応 observer である。




図 1: Project 1 の closed-loop pipeline。true state は評価専用で、controller は estimator output のみを見る。

1.4. なぜ closed-loop pipeline を考えるのか

この pipeline は、単にソフトウェアを複雑にしたいから作っているのではない。研究上の目的は、状態推定の質が、実際の筋骨格 reaching の制御性能に伝播するかを調べることである。

open-loop evaluation では、記録済み trajectory を replay しながら $\hat{x}_{hat_t}$ と x_t の誤差を測る。これは forward model や estimator の純粋な精度を見るには有用だが、次の問いには答えられない。

closed-loop でしか答えられない問い

推定状態 $\hat{x}_{hat_t}$ が少し良くなったとき、controller が実際に違う muscle excitation を出し、腕の軌道や到達誤差が変わるのか。

この問いに答えるには、estimator を controller の前段に置き、推定誤差が action を通じて plant に戻る循環を作る必要がある。これが closed-loop pipeline である。

評価	測れること	測れないこと
open-loop	state estimation error, prediction MSE, oracle K	その推定が行動に効くか
closed-loop	reaching error, success, overshoot, 推定誤差の行動への伝播	純粋な estimator 精度だけの切り分けは難しい

したがって、Project 1 では open-loop と closed-loop を両方使う。open-loop は estimator の診断、closed-loop は「その推定が制御に意味を持つか」の検証である。

1.5. このループは妥当なのか

この closed-loop は、神経科学的にも制御工学的にも妥当な抽象化である。ただし「脳を完全再現している」という意味ではない。

観点	妥当な理由	限界
神経科学	efference copy に基づく forward prediction と delayed sensory feedback の統合を表す	小脳 microcircuit, spike, climbing fiber learning は再現していない
制御工学	observer + controller という標準的な閉ループ構造	gain は scalar で、完全な covariance 推定から導出した最適 gain ではない
実験設計	true state を評価専用にし、controller は estimated state だけを見るため、state estimation の効果を検証できる	controller の質が低いと estimator 差が task に出ない

Project 1 の closed-loop は、以下の仮説を検証するための最小構成である。

delayed/noisy sensory feedback
+ forward prediction
+ sensory prediction-error correction
-> better estimated current state
-> different controller action
-> different reaching trajectory

この連鎖のどこかが切れると、状態推定が良くても task performance には出ない。実際、behaviour-cloned policy では reaching は改善したが state coupling が弱く、observer signal は wash out した。逆に joint-space feedback controller と endpoint-error sensorimotor policy は state-coupled なので、推定状態の差が task 指標に現れた。

研究ノート

closed-loop pipeline の妥当性は「controller が良い」ことではなく、「controller が推定状態に依存している」ことにある。Project 1 の主結果は、状態推定の効果が state-coupled controller と observation-delay regime の組み合わせで現れる、という点である。

1.6. Downstream policy の 3 分類

論文が一段落した時点で、controller 軸は次の 3 分類に整理された。ここでは controller を広い意味で使うが、BC と endpoint-error は policy と呼ぶ方が正確である。

名前	何を見るか	位置づけ
joint-space feedback controller	joint error / velocity error から muscle excitation を出す	hand-designed, joint-level, state-coupled
endpoint-error sensorimotor policy	estimated tip-to-target error から muscle excitation を出す	task-level, endpoint-error-driven, state-coupled
behaviour-cloned policy	demonstration から state-to-action mapping を学習する	minimal learned sensorimotor policy

endpoint-error sensorimotor policy は、OFC-like controller や LQR-like controller ではない。Riccati equation、LQR、OFC を解いているわけではなく、推定された手先誤差に基づいて筋入力を補正する transparent な task-level policy である。

研究ノート

この 3 分類の意味は、「どの policy が一番 reaching できるか」だけではない。observer の出力 $\hat{x}_t$ が downstream policy の action に実際に伝わるか、つまり state coupling があるかを見るための軸である。

1.7. Closed-loop pipeline を時刻順に読む

Fig. 1 の closed-loop pipeline は、1 control step ごとに同じ処理を繰り返す。重要なのは、シミュレータ内部には常に真の状態 x_t があるが、controller はそれを直接見ないという点である。controller が見るのは、delay/noise wrapper と estimator を通った $\hat{x}_t$ だけである。

順序	モジュール	入力 -> 出力	研究上の意味
1	MuJoCo / MyoSuite plant	$u_{t-1} \rightarrow \text{true state } x_t$	身体が実際にどう動いたか。これは評価用 oracle であり controller には渡さない。
2	state extractor	$\text{mj_data} \rightarrow \text{MyoArmState}(x_t)$	q_{pos} , q_{vel} , a_{ct} , tip_pos , target_pos , reach_err を研究用 schema に整える。
3	observation wrappers	$x_t \rightarrow \text{delayed/noisy observation } y_t$	感覚遅延・観測ノイズを明示的に入れる。生体の sensory feedback 制約に対応。
4	forward model	$\hat{x}_{t-1}, u_{t-1} \rightarrow \text{prediction } \hat{x}_{\text{pred}_t}$	efference copy と前状態推定から現在状態を予測する。
5	predictive state observer	$\hat{x}_{\text{pred}_t}, y_t, \text{correction gain } K \rightarrow \text{estimate } \hat{x}_t$	sensory prediction error を補正し、controller が使う現在状態を作る。
6	controller	$\hat{x}_t \rightarrow \text{neural command / excitation } u_t$	推定状態に基づいて次の筋入力を決める。
7	ActionAdapter + SDN	$\text{excitation} \rightarrow \text{api_action}$	必要なら signal-dependent motor noise を入れ、Gym API 形式へ変換する。
8	$\text{env.step}(\text{api_action})$	$\text{api_action} \rightarrow \text{next plant state}$	次の時刻へ進む。
9	logger / metrics	$\text{true_state}, \text{observation}, \text{estimate}, \text{action}$	評価・学習・再現のために全層を保存する。

確認ポイント

closed-loop の核心は、 $\text{true_state} \rightarrow \text{observation} \rightarrow \text{estimator} \rightarrow \text{controller} \rightarrow \text{action} \rightarrow \text{plant}$ の循環である。 true_state は metrics と supervised training には使うが、closed-loop controller の入力にはしない。

1.8. 1 step の擬似コード

実装の概念は次のように読める。これは実際の関数名を完全に写したものではなく、責務を理解するための擬似コードである。

```
# t 時点。env 内部には真の MuJoCo state がある。
true_state = extract_state(env)      # oracle for logging/evaluation only

# 生体という sensory feedback。ここで delay/noise が入る。
obs_state = delayed_wrapper.observe(true_state)
obs_state = noisy_wrapper.observe(obs_state)

# 前 step の推定状態と実際に入れた muscle excitation から現在を予測。
x_pred = forward_model.predict(prev_estimate, prev_excitation)

# sensory prediction error を correction gain K で補正。
```

```
estimate = estimator.update(prediction=x_pred, observation=obs_state, gain=K)
```

```
# controller は estimate だけを見る。true_state は見ない。
neural_command = controller(estimate)
excitation = command_to_excitation(neural_command)
excitation = motor_noise(excitation) # optional SDN
api_action = action_adapter.to_api(excitation)
```

```
# plant を1 step進める。
```

```
obs, reward, terminated, truncated, info = env.step(api_action)
```

```
# 後で検証できるように、true / obs / estimate / action を全部保存。
```

```
logger.append(
    true_state=true_state,
    obs_state=obs_state,
    estimate=estimate,
    neural_command=neural_command,
    excitation=excitation,
    api_action=api_action,
)
```

このコードで最も大切なのは、`controller(estimate)` であって `controller(true_state)` ではないことだ。true state controller は oracle baseline としては有用だが、Project 1 の本筋ではない。

1.9. delay がない場合とある場合

delay が $d=0$ の場合、observation y_t は現在状態 x_t の noisy version と見なせる。このとき prediction-error correction は直感的である。

```
x_pred_t = forward_model(xhat_(t-1), u_(t-1))
y_t = x_t + noise
xhat_t = x_pred_t + K * (y_t - x_pred_t)
```

delay が $d>0$ の場合、 y_t は現在ではなく過去 $x_{(t-d)}$ の観測である。したがって、単純に x_{pred_t} と y_t を混ぜると時刻がずれる。Project 1 では fixed-lag buffer を使い、過去の estimate を correction してから現在まで re-roll する。

1. buffer 内に $xhat_{(t-d)}$, ..., $xhat_{(t-1)}$ と action を保持
2. y_t は $x_{(t-d)}$ の観測なので、 $xhat_{(t-d)}$ に対して correction
3. corrected $xhat_{(t-d)}$ を $u_{(t-d)}$, ..., $u_{(t-1)}$ で forward model rollout
4. 現在時刻の estimate $xhat_t$ を得る

落とし穴

delay があるときに y_t を現在状態として扱うと、推定器は「古い身体状態」を現在だと思って制御する。この誤りは reaching の振動・遅れ・overshoot として現れる。

1.10. correction gain K の直感

ここでの K は Kalman filter から導出した gain ではない。 K は sensory prediction error に対する correction gain であり、forward prediction と sensory feedback のどちらをどの程度信じるかを表す実験上の knob である。

K	推定器の挙動	closed-loop で起きやすいこと
$K=0$	prediction-only。observation correction を使わない。	forward model が強ければ delay を回避できるが、model error があると発散する。
$K=1$	observation-only。prediction は correction 後の re-roll 以外では弱い。	観測が新鮮なら強い。delay が大きいと古い情報に引っ張られる。
$0<K<1$	prediction と observation の blending。	観測ノイズが大きく、delay が小さい条件では有利になりやすい。

この研究で重要だったのは、open-loop state estimation error を最小にする K と、closed-loop task error を最小にする K が一致しない場合があることだった。つまり「状態推定として正確」でも「制御に使うと良い」とは限らない。

1.11. logger に全層を保存する理由

closed-loop pipeline では、1 step ごとに似たような vector が複数出てくる。これらを保存しないと、失敗したときに原因を切り分けられない。

保存する量	用途	典型的な診断
true_*	oracle evaluation / supervised training	estimation error が本当に下がったか
obs_*	delay/noise 後の観測	wrapper の設定が効いているか
estimate_*	controller 入力	controller が何を信じて動いたか
neural_command	抽象的 controller output	将来の cortical module との接続
excitation	canonical muscle input	SDN 後に何が plant に入ったか
api_action	Gym API input	ActionAdapter の変換確認
activation	muscle internal state	筋 dynamics の遅れや飽和

演習 / 作業

closed-loop の結果を読むときは、まず `final_tip_error` を見るのではなく、同じ episode の `true_tip_pos`, `obs_tip_pos`, `estimated_tip_pos`, `excitation` を並べる。どの層で差が生まれたかを見ないと、estimator の効果と controller の癖を混同する。

2. 必要な前提知識

2.1. 筋骨格 reaching と MyoSuite

MyoSuite myoArm は、MuJoCo 上で動く筋骨格腕モデルである。Project 1 で主に扱うのは、示指先端を target に近づける reaching task である。




図 2: myoArm reaching task の概念図。リポジトリ内 primer の既存画像を使用。

落とし穴

この図の胸部付近にある円形マークは、元画像に含まれるロゴ / 透かしであり、筋・骨・関節・センサーなどのモデル要素ではない。著作権表示や出典表示を意図したマークを削除・改変して使ってはいけない。投稿・配布用の図では、(1) 元画像を改変せず出典とライセンスに従って使う、または (2) 自分で MuJoCo からレンダリングした図に差し替える、のどちらかにする。

項目	値 / 形	注意
muscles	34	action / excitation dimension
joint position	q in $\mathbb{R}^{20}$	MyoSuite / MuJoCo の qpos
joint velocity	$\dot{q}$ in $\mathbb{R}^{20}$	qvel
activation	a in $\mathbb{R}^{34}$	筋内部状態。command ではない
control step	0.02 s	MuJoCo internal timestep 0.002 s と混同しない
episode	600 steps = 12 s	horizon と max_steps を揃える

落とし穴

MyoSuite の observation は便利だが、研究用の状態 schema と一致するとは限らない。本研究では mj_data から true state を抽出し、MyoArmState として明示的に管理する。

2.2. 信号名の区別

この研究で最も重要な実装原則は、作用信号の層を混同しないことである。

neural_command

controller が出す抽象的な運動指令。将来、cortical population dynamics の出力になる可能性がある。

excitation

研究側 canonical 表現。筋 actuator 入力として解釈する $[0,1]^{34}$ 。

api_action

Gym / MyoSuite の env.step() に渡す $[-1,1]^{34}$ 。

activation

筋モデル内部の活性化状態。controller output ではない。

mj_data.ctrl

MuJoCo の actuator control。post-step inspection 用。

true_state

シミュレータ内部の真値。oracle baseline と評価以外では controller に渡さない。

基本変換は次である。

```
api_action = 2.0 * np.clip(excitation, 0.0, 1.0) - 1.0
excitation = (np.clip(api_action, -1.0, 1.0) + 1.0) / 2.0
```

確認ポイント

論文・コード・ログで action とだけ書かれていたら、そのたびに「どの層の action か」を確認する。特に SDN は api_action ではなく neural_command / excitation 側に入れる。

2.3. 状態ベクトル

Project 1 の状態は次の 83 次元ベクトルである。

```
x_t = [qpos, qvel, act, tip_pos, target_pos, reach_err]
dim = 20 + 20 + 34 + 3 + 3 + 3 = 83
```

ここで reach_err は、現在の論文では target_pos - tip_pos として扱う。

field	dim	意味
qpos	20	関節位置
qvel	20	関節速度

act	34	筋 activation
tip_pos	3	示指先端位置
target_pos	3	target 位置
reach_err	3	target_pos - tip_pos

3. Forward model

3.1. なぜ forward model が必要か

感覚 feedback に delay がある場合、時刻 t に届く observation は過去の状態 x_{t-d} に対応する。したがって controller が現在状態 x_t に基づいて動くには、過去の観測を forward model で現在まで転がす必要がある。




図 3: open-loop oracle gain の heatmap。forward model の訓練方法により、どの delay/noise 条件で prediction を信じるべきかが変化する。

3.2. 残差 MLP

Project 1 の baseline forward model は residual MLP である。

input: $[x_t, u_t]$ in $\mathbb{R}^{(83 + 34)}$

output: Δx_t in $\mathbb{R}^{83}$

predict: $\hat{x}_{t+1} = x_t + f_{\theta}(x_t, u_t)$

残差形式を使う理由は、control step が短く、隣接状態の差分が小さいためである。モデルは identity map を再学習するのではなく、状態変化だけを学ぶ。

3.3. one-step と multi-step supervision

one-step loss:

$$L_1(\theta) = \mathbb{E}[\|f_{\theta}(x_t, u_t) - (x_{t+1} - x_t)\|^2]$$

multi-step rollout loss:

$$L_H(\theta) = \mathbb{E}\left[\frac{1}{H} \sum_{h=1}^H \|\hat{x}_{t+h} - x_{t+h}\|^2\right]$$

ここで H は rollout supervision horizon である。論文の中では、correction gain の K と混同しないよう、rollout horizon を H と呼ぶ。

訓練	利点	リスク
$H=1$	実装が簡単、one-step MSE が下がりやすい	long rollout で誤差が蓄積
$H=4$	短期 rollout を安定化	訓練が重い
$H=8$	closed-loop で prediction-only が使える領域が広がる	open-loop oracle と closed-loop optimum の乖離が大きくなる

研究ノート

Project 1 の重要な発見は、forward model を強くすると「よりよい blending」が得られるだけでなく、closed-loop objective では $K=0$ prediction-only が支配的になる条件が現れることだった。

4. Predictive state observer

4.1. 基本式

Project 1 の推定器は、完全な Kalman filter ではない。神経科学的に重要なのは Kalman 最適性ではなく、efference copy に基づく forward prediction と、遅延・ノイズ付き sensory feedback から生じる sensory prediction error を、closed-loop 行動に有用な形で統合できるかである。

最小形の update は次である。

$$\hat{x} = x_{\text{pred}} + K(y - x_{\text{pred}})$$

ここでは K は $[0,1]$ の scalar として全 field に broadcast する。 K は Kalman covariance から計算した gain ではなく、sensory prediction error correction gain である。

落とし穴

この推定器を「Kalman filter」と呼ばない。共分散 P 、process noise Q 、observation noise covariance R を伝播して最適 gain を計算しているわけではない。本文では predictive state observer または forward-model-based observer と呼び、Kalman は「innovation update と似た形を持つ」という補足に留める。

この式の各項は次のように読む。

項	意味	注意
x_{pred}	forward model だけで作った予測	まだ観測で補正していない
y	遅延・ノイズ付き観測	delay がある場合は現在ではなく過去の状態を見ている
$y - x_{\text{pred}}$	sensory prediction error、予測と観測のずれ	神経科学的には感覚誤差補正信号として読む
K	prediction error をどれだけ推定に反映するか	0 なら感覚誤差を無視、1 なら観測に寄せる
$\hat{x}$	補正後の推定状態	controller に渡す状態

したがって x_{pred} は estimator の途中結果であり、 $\hat{x} / x_{\text{hat}}$ は estimator の出力である。

K	意味	直感
0	prediction-only	forward model を完全に信じる
1	observation-only	delayed/noisy observation を完全に信じる
$0 < K < 1$	blending	prediction と observation を混ぜる

4.2. fixed-lag delay handling

delay が d step ある場合、観測 y_t は現在ではなく $t-d$ の状態に対応する。そこで estimator は過去の estimate と action buffer を保持する。

buffer: $x_{\text{hat}}(t-d), \dots, x_{\text{hat}}(t-1)$

obs: $y_t = x(t-d) + \text{noise}$

1. delayed buffer entry $x_{\text{hat}}(t-d)$ を observation で correction
2. corrected $x_{\text{hat}}(t-d)$ を action buffer で t まで re-roll
3. controller は present estimate x_{hat}_t を使う

落とし穴

delay wrapper の意味を変えない。Project 1 では $\text{observe}(s_t) \rightarrow s_{t-d}$ とし、delay buffer length と correction semantics を一貫させる。

4.3. 二層 reliability-adaptive observer

ここまでの定式化では κ は固定 scalar である。Project 1 の中心提案は、 κ を agent 自身が online で生成できる信号 から動的に決める二層適応則である。

二層適応則の骨格

1. Within-trial layer: 各 sensory field の innovation 二乗を EMA で追跡 $\rightarrow$ reliability $r_{f(t)} \rightarrow$ logistic で per-field gain $K_{f(t)}$ 。
2. Across-trial layer: SPSA で meta-parameter $\beta = \{\beta_{0,f}, \beta_{1,f}\}$ を per-episode reaching outcome から更新。

agent-available signals

agent 自身が観測・計算可能なシグナルのこと。 y_t (観測)、 $\hat{x}_t(t-d)$ (自分の推定)、 u_t (自分の出した運動指令)、reach 終了後の $\min_t |\text{tip} - \text{target}|$ などが含まれる。 x_t (真の状態)や per-condition の K-sweep oracle ラベルは含まれない。

4.3.1. 二層の役割と時間スケール

ここでいう「trial」は 1 回の reach episode(600 step $\times$ 0.02 s = 12 秒)を指す。二層適応則は、この trial の中と外で異なる学習を回す。

	within-trial layer	across-trial layer
時定数	~ 20 step (≈ 0.4 s)	~ 100 trial(数十分～数時間)
信号源	step ごとの innovation $e_t = y_t - \hat{x}_{t-d}$	trial 終了後の outcome $\min \text{Tip}(\beta)$
何が変わるか(state)	field-wise EMA variance $v_{f(t)}$ 、つまり gain $K_{f(t)}$ そのもの	meta-parameter $\beta = \{\beta_{0,f}, \beta_{1,f}\} \in \mathbb{R}^{10}$
何が固定(input)	β は固定 const として与えられる	β を動かす(within-trial dynamics ごと書き換える)
生物学的読み(coarse)	小脳 microcircuit で常時走る per-channel error monitoring	シナプス可塑性 / consolidation レベルの slow learning

4.3.1.1. Step-wise signal flow (within-trial)

[step t]

- ① 観測到着 $y_t = x_{t-d} + \text{noise}$ (delay d 前の状態のノイズ版)
- ② innovation $e_t = y_t - \hat{x}_{t-d}$
- ③ field-wise EMA $v_f(t) = (1 - \alpha) v_f(t-1) + \alpha \cdot \text{mean}(e_t[\text{field } f]^2)$
- ④ reliability $r_f(t) = 1 / (\epsilon + v_f(t))$
- ⑤ logistic gain $K_f(t) = \sigma(\beta_{0,f} + \beta_{1,f} \cdot \log r_f(t))$
- ⑥ correction $\hat{x}_{t-d} \leftarrow \hat{x}_{t-d} + K_f(t) \cdot (y_t - \hat{x}_{t-d})$
- ⑦ buffer update + 次の予測へ

ここで学習されているのは $v_f(t)$ という EMA state(= memory cell に近い動的状態)であり、重みパラメータ β は触らない。episode 開始時に $v_{f(0)} = 1$ から始まり、その episode 中に shape される。次の episode でも v_f はリセットされる。

4.3.1.2. Iteration-wise signal flow (across-trial)

[SPSA iteration n] (= 何回かの episode のセット)

- ① $\Delta_n \sim \text{Rademacher}(\{-1, +1\})^{10}$
- ② "+ 側" S 個 episode で outcome を平均
 $\beta_n + c_n \cdot \Delta_n \rightarrow o_{\text{plus}} = \text{mean of } S \min \text{Tip}(s)$
- ③ "- 側" 同様
 $\beta_n - c_n \cdot \Delta_n \rightarrow o_{\text{minus}}$
- ④ 中央差分の SPSA 勾配:


$$\hat{g}_n = (o_{plus} - o_{minus}) / (2 c_n) \cdot \Delta_n^{-1}$$

⑤ β を更新:

$$\beta_{n+1} = \beta_n - a_n \cdot \hat{g}_n$$

ここで学習されているのは β そのもの。within-trial 動態 v_f ではなく、その動態を支配する logistic のパラメータが書き換わる。SPSA は 10 次元の β 空間を 1 iteration あたり 2 評価で探索できる(Rademacher 摂動による単一同時摂動)ので、有限差分($2 \times 10 = 20$ 評価)より次元スケーラブル。

4.3.1.3. 二層の関係



within-trial は β を入力として固定 const に取り、innovation history を進化させて episode 中に $K_{f(t)}$ を動かす。across-trial は episode 終了後に β を書き換える、次 episode 以降の within-trial dynamics を変える。

4.3.1.4. なぜ二層に分けるか

C1(default reliability が task-misaligned)が直接の動機。

1. innovation を見れば sensor 信頼度 は分かる。だが「forward model が task に十分良いから sensor は要らない」は分からない。これは 試行の結末(= reach の outcome)を見ないと判別できない。
2. 一方で、毎 step outcome 信号を待つことはできない。reach が終わるまで minTip は確定しない。
3. したがって innovation で step ごとに即応(within-trial)+ outcome で trial 間で slow correction(across-trial)という二層構成が自然な解になる。

C2 の主結果 = across-trial layer が 1 cell で 17 / 23 cm の gap を埋める = 「outcome を加えて初めて task-aware adaptation になる」を直接示している。C3 の限界 = β 一つで multi-cell に対応できない = across-trial layer の parameterisation 限界(SPSA 限界ではない)。次の自然な拡張は β 自体を context-conditioned network 化すること(Project 1.5)。

4.3.2. Within-trial layer: innovation history から reliability へ

各 step、観測 y_t と過去 estimate の差分(innovation)を計算する。

$$e_t = y_t - \hat{x}_{t-d}$$

これは古典的 Kalman の innovation と同じ residual である。Project 1 ではこの 83 次元 vector を 5 つの sensory field に分けて扱う。

field	次元	生物学的読み(coarse)
qpos	20	proprioceptive(joint position)

qvel	20	proprioceptive(joint velocity)
act	34	efferent / muscle-command-like
tip_pos	3	visual / task-space
reach_err	3	visual / task-space(target との差)

target_pos(3 次元)は信頼度学習の対象外。target は既知量で prediction error が意味を持たない。

4.3.2.1. EMA(Exponential Moving Average / 指数移動平均)とは

時系列 $x_1, x_2, \dots, x_t$ の「現在の平均」を、過去ほど指数的に重みを下げて推定する手法。再帰的に次で定義する。

$$v(t); =; (1 - \alpha) \cdot v(t-1); +; \alpha \cdot x_t$$

- $\alpha \in (0, 1)$: smoothing factor / 学習率
- $v(0)$: 初期値(Project 1 では $v_f(0) = 1$)

この再帰を展開すると、

$$v(t); =; \alpha x_t + \alpha(1 - \alpha)x_{t-1} + \alpha(1 - \alpha)^2 x_{t-2} + \dots$$

過去のデータには $(1 - \alpha)^k$ で指数減衰する重みがかかる。重みの大半が含まれる effective window は近似的に $\frac{1}{\alpha}$ step。

α	effective window	性格
0.5	~ 2 step	ほぼ直近の値そのもの
0.1	~ 10 step	短期平均
0.05 (Project 1)	~ 20 step	paper の中時間スケール(≈ 0.4 s)
0.01	~ 100 step	長期 trend
0.001	~ 1000 step	ほぼ episode 全体

Project 1 の $\alpha = 0.05$ は、step = 0.02 s で ≈ 0.4 秒の窓。reach episode 12 秒の 3% 程度。瞬間 noise spike には過剰反応せず、reach 中盤での sensor 信頼度変化には追従できる選び方。

4.3.2.2. Simple Moving Average との対比

	SMA(window N)	EMA(rate α)
定義	$v(t) = \frac{x_{t-N+1} + \dots + x_t}{N}$	$v(t) = (1 - \alpha)v(t-1) + \alpha x_t$
memory	window N 個の過去値を保持	スカラ $v(t-1)$ 1 個だけ
計算量	$O(N)$ per step	$O(1)$ per step
窓の縁	hard cutoff($N + 1$ step 前は重み 0)	soft cutoff(指数減衰)
直近重視	全要素均等	直近に重み大

EMA の利点は memory が 1 スカラで済むこと。Project 1 では 5 つの sensory field $\times$ per-step 更新なので、SMA だと window 長さ分の buffer $\times 5$ field 必要。EMA なら $v_{f(t)}$ を 5 個のスカラで完結できる。

4.3.2.3. Project 1 での具体的使用

各 field の 2 乗 innovation 平均を EMA で追跡する。

$$v_{f(t)}; =; (1 - \alpha) \cdot v_{f(t-1)}; +; \alpha \cdot \text{mean}_{i \in \mathcal{I}_f}(e_{t,i}^2)$$

alpha=0.05 だと時定数 20 step、1 episode の 3% 程度の窓。 v_f が小さい = innovation が一貫して小さい = sensor 信頼できる。逆に大きい = sensor 信頼できない。

なぜ二乗を取るか

innovation e_t そのものの平均は、forward model が unbiased なら(平均的に) 0 に近い。「sensor が信頼できるか」を測りたいので、分散 / 二乗誤差 を見たい。二乗平均は分散の推定量(mean が 0 と仮定す

れば $E[e^2] = \text{Var}(e)$ 。これは古典的 adaptive Kalman filter(Mehra 1970)が innovation sequence から noise covariance を推定するのと同じ発想。

4.3.2.4. 動作例((none, d=18) cell, qvel field)

t=0: v_qvel = 1.0 (初期値)
t=1: e_t^2 = 0.02 (sensor 信頼できる)
v_qvel = 0.95*1.0 + 0.05*0.02 = 0.951
t=2: e_t^2 = 0.05
v_qvel = 0.95*0.951 + 0.05*0.05 = 0.906
...
t=200: v_qvel ≈ 0.4 (running variance に近づく)
t=400: v_qvel ≈ 0.38 (定常状態)

v_qvel が下がる → reliability $r_f = \frac{1}{\varepsilon + v_f}$ が上がる → logistic K_f が大きくなる → sensor を信じる。逆に innovation が暴れる cell では v_f が高止まりし、 K_f は下がる。

Project 1 の tab:default_kf で qvel だけが $K = 0.31 - 0.49$ と他 field より低い水準に張り付くのは、qvel の innovation 二乗が比較的高め(joint velocity は MyoSuite では振動成分が乗りやすい)で reliability が抑えられているため。

4.3.2.5. 生物学的解釈

EMA は神経生物学的にも自然な実装。脳の neural integrator(leaky integrator)は連続時間で

$$\tau \dot{v}(t); =; -v(t) + \text{input}(t)$$

を解く回路。これを Δt で離散化すると

$$v(t + \Delta t); =; \left(1 - \Delta \frac{t}{\tau}\right), v(t) + \left(\Delta \frac{t}{\tau}\right), \text{input}(t)$$

5. EMA 形式と等価。 $\alpha = \Delta \frac{t}{\tau}$ 、つまり EMA の α は神経 leaky integrator の time constant τ の逆数に対応する。

biological reading

Project 1 の within-trial layer は、innovation の二乗を入力とする生物学的 leaky integrator と読める。小脳 / 大脳基底核の short-time-scale neural integrator が、step ごとの sensory prediction error の大きさを統合し続けている、というモデルに対応する。

reliability に変換:

$$r_{f(t)}; =; \frac{1}{\varepsilon + v_{f(t)}}$$

そして logistic で per-field gain $K_{f(t)}$ に写像:

$$K_{f(t)}; =; \sigma(\beta_{0,f} + \beta_{1,f}, \log r_{f(t)})$$

parameter	意味	直感
$\beta_{0,f}$	intercept	$r_f = 1(\log r = 0)$ 時の baseline gain $K_f = \sigma(\beta_{0,f})$ 。例えば $\beta_{0,f} = -1.5$ なら baseline $K_f \approx 0.18$ 。
$\beta_{1,f}$	slope	reliability の変化に gain がどれだけ強く反応するか。 $\beta_{1,f} = 0$ なら gain は固定、 $\beta_{1,f}$ が大きいほど innovation 増減で gain が大きく動く。

直感

innovation が暴れる → reliability が下がる → K_f が小さくなる → sensor を信じず forward model を

信じる。

innovation が落ち着く $\rightarrow$ reliability が上がる $\rightarrow K_f$ が大きくなる $\rightarrow$ sensor を信じる。

この per-field 動的調節を innovation history だけ から行うのが within-trial layer。

5.0.1. Across-trial layer: SPSA outcome adaptation

within-trial layer の挙動は $\beta = \{\beta_{0,f}, \beta_{1,f}\} \in \mathbb{R}^{10}$ に支配される。 β をどう決めるかは、reach 終了後の reaching outcome から学習する。

outcome は per-episode の minimum tip-to-target distance:

$$\text{minTip}(\beta); =; \min_{t \in [0, T]} |p_{\text{tip}}(t) - p_{\text{tgt}}|$$

これは生体の場合「reach 後どこに着いたかの視覚 + proprioception 由来の評価」に対応する scalar。 minTip 自体は biological claim ではなく、agent-available な outcome の operational proxy として使う。

closed-loop minTip は β に対して解析的勾配を取れないので(env step $\rightarrow$ EMA $\rightarrow$ sigmoid $\rightarrow$ control $\rightarrow$ non-smooth min を経由する)、SPSA(Spall 1992)で勾配 free 最適化する。

SPSA 1 iteration:

```
Delta_n ~ uniform([-1, +1])^10 // Rademacher perturbation
o_plus = minTip(beta_n + c_n * Delta_n) // S 個 episode 平均
o_minus = minTip(beta_n - c_n * Delta_n) // S 個 episode 平均
g_hat = (o_plus - o_minus) / (2 c_n) * Delta_n^{-1}
beta_{n+1} = beta_n - a_n * g_hat
```

Spall schedule:

```
a_n = a / (n + 1 + A)^alpha_s
c_n = c / (n + 1)^gamma_s
```

defaults: a=2.0, c=0.3, alpha_s=0.602, gamma_s=0.101, A=5, S=10 or 12。

Black-box stochastic approximation

最適化対象の中身を見ずに、入力を摂動して出力(scalar evaluation)を観測するだけで勾配推定する手法群。SPSA はそのうち最も次元スケーラブルなアルゴリズム。policy search / Evolution Strategies と同じカテゴリ。

Project 1 では SPSA を 2 つの設定で走らせた:

variant	training cells	使い道
single-cell	($\sigma = \text{none}, d = 18$) の 1 cell のみ	agent-available adaptation が closed-loop oracle に追いつけるかの存在証明 (C2)
full-grid	3 noise $\times$ 2 delay = 6 cell から uniform random sampling	single global β で grid を覆えるかの structural test (C3)

5.0.2. oracle-supervised predictor: upper bound diagnostic (Appendix C 教材)

提案手法と対比される旧 main contribution(現 Appendix C)は、condition feature (sigma, d, c) から scalar K を出す MLP を、per-condition の K-sweep oracle ラベルで supervised に学習する。

$g_phi : (\text{one_hot}(c), \text{sigma}, d/d_max) \rightarrow K$ in $[0, 1]$

oracle ラベルは 2 種類:

oracle	定義	最適化するもの
$K^*_{\text{"ol"}}$	$\text{argmin}_K E[\ \hat{x}_t(K) - x_t\ ^2]$	open-loop state estimation error
$K^*_{\text{"cl"}}$	$\text{argmin}_K E[\text{minTip}(K)]$	closed-loop reaching error

Appendix C 教材としての位置

oracle-supervised predictor は agent-available ではない: per-condition の K-sweep を回す段階で生体

には不可能な data 収集を要求する。提案手法と直接比較するための non-agent-available upper bound として Appendix C に残してある。

重要な観察: closed-loop oracle K_{cl}^* と open-loop oracle K_{ol}^* は乖離することがあり、特に multi-step supervision された forward model 下で顕著(closed-loop で $K = 0$ が optimal なのに、open-loop oracle では $K = 1$ が optimal)。これは learned correction gain を評価する際に 何を教師 oracle としたかを明示すべきだという、Appendix C の中心的指摘である。

6. 実験 pipeline

6.1. Repository の構造

```
src/myoarm_fse/    Python package
scripts/          CLI scripts
configs/          YAML configs
runs/             local outputs; large artifacts are not versioned
tests/            unit and smoke tests
docs/             plans, primers, this textbook
figures/          paper figures and CSV summaries
paper/            TNNLS manuscript
```

環境構築とテストは uv を使う。

```
uv sync
uv run pytest
uv run pytest -m mysuite
```

落とし穴

Python を使う場合は python 直実行ではなく uv run python ... を使う。依存関係と仮想環境を固定するためである。

6.2. 最小再現手順

研究を最初から再現する場合の概念的な手順は以下である。実際のファイル名は configs/ と scripts/ を確認する。

Step	作業	確認する出力
1	target set 生成	runs/targets/*.npz
2	episode collection	runs/episodes/<timestamp>/
3	TransitionDataset 作成 / concat	runs/datasets/*.npz
4	forward model training	runs/models/<timestamp>/
5	open-loop estimator sweep	runs/estimators/<timestamp>/metrics.csv
6	learned gain training	runs/learned_gain_models/<timestamp>/
7	closed-loop evaluation	runs/closed_loop/<timestamp>/metrics.csv
8	paper figures	figures/F*.png, figures/data/*.csv

6.3. 実験 command の読み方

代表的な command は次の形になる。

```
uv run python scripts/train_forward_model.py \
--config configs/models/mlp_expanded.yaml

uv run python scripts/evaluate_estimator.py \
--config configs/estimators/fixed_kalman_robustness.yaml \
--forward-model runs/models/<model-id>
```

```
uv run python scripts/evaluate_closed_loop.py \
--config configs/closed_loop/<config>.yaml
```

設定 YAML を変えるときは、実験条件を run directory に保存し、後で paper figure を再生成できるようにする。

7. 主要結果の読み方

ここまでで、closed-loop pipeline、forward model、predictive state observer、二層適応則(within-trial reliability + across-trial SPSA)、そして Appendix C の oracle-supervised upper bound を説明した。ここからは、その道具を使って論文の主張 C1-C4 を読む。

Claim	内容	意味
C1	default within-trial reliability ($\beta_{0,f} = 0, \beta_{1,f} = 0.5$)は field-wise heterogeneous な中-高 gain を出し、 $H = 8$ 下では task-optimal $K = 0$ から 23-29 cm 外す	innovation だけでは task を知らない
C2	single-cell SPSA は trained cell 上で default-reliability vs $K = 0$ gap の 23 cm のうち ≈ 17 cm を回復($0.77 \rightarrow 0.56$ m vs $K = 0$ at 0.50 m)	outcome layer を足せば agent-available signal だけで closed-loop optimum に近づく
C3	multi-cell SPSA は delay-18 cells で 3-5 cm の改善どまり、delay-0 cells で改善ゼロ。SPSA の失敗ではなく、global single- β の parameterisation が underpowered	次の model class は context-conditioned β
C4	ReachFixed-trained β を ReachRandom に転移すると全 delay-18 cells で $K = 0$ を $\sim 4-5$ cm 下回る。default reliability の方が逆に競合的	correction-gain rule は task-dependent (K_{cl}^* geometry に依存)

7.1. C1: default reliability is task-misaligned

F_reliability_default は、 $H = 8$ forward model + joint-PD controller 下で $K = 0$ / $K = 1$ / default reliability($\beta_{0,0}=0, \beta_{1,0}=0.5$)の closed-loop min-tip を 6 cell で比較した結果である。




図 4: default within-trial reliability は $K=0$ を 23-29 cm 下回る。 $K_{cl}^*=0$ 一様な ReachFixed grid 下で innovation reliability だけでは task-optimal な gain を出せない構造的限界を示す。

実 diagnostic dump から、default rule が出す per-field K_f は強く非対称:

cell	qpos	qvel	act	tip_pos	reach_err
none, d=0	0.96	0.49	0.91	0.97	0.98

none, d=18	0.70	0.31	0.69	0.59	0.68
high, d=0	0.96	0.49	0.92	0.96	0.97
high, d=18	0.69	0.32	0.71	0.68	0.69
xhigh, d=0	0.90	0.45	0.91	0.94	0.94
xhigh, d=18	0.67	0.31	0.69	0.64	0.68

つまり default rule のもとでは、qvel だけが一貫して低 gain (0.31-0.49)、他 4 field は中-高 gain(0.59-0.98)に張り付く。innovation reliability は task を知らないなので、 $K_{cl}^* = 0$ という task-optimal な水準には届かない。

C1 の核心

innovation だけ追っても、forward model がどれくらい task に有用かは分からない。

sensor 信頼度と “forward model に任せて良いか” は別の情報。

後者は task outcome を見ないと決まらない。

7.2. C2: single-cell SPSA closes most of the gap

F_spsa_single は、($\sigma = \text{none}, d = 18$) という 1 cell 上で SPSA を 100 iteration 回した結果である。




図 5: 上: per-iter outcome trajectory(青)+ 10-iter running mean(濃青)+ $K = 0$ baseline 0.50 m(橙破線)。下: final β 。qpos は intercept (-1.5)も slope ($+0.9$)も先頭で、field-wise specialisation が outcome から自動生成される。

主要数値:

- per-iter outcome は $\approx 0.61 \text{ m} \rightarrow \approx 0.53 \text{ m}$ に下降(last iter)
- 10-iter running mean(訓練時 smoothed signal)は $K = 0$ baseline 0.50 m まで一瞬到達
- 別途 fresh deployment(final β を独立 10 episode に適用)で min-tip = 0.56 m $\rightarrow$ residual $\sim 6 \text{ cm}$
- default reliability(0.77 m)と比べて 0.77 $\rightarrow$ 0.56 の 17 cm gap recovery

C2 の核心

agent は K-sweep oracle ラベルを使わずに、per-episode reaching outcome だけから β を更新できる。
trained cell では default reliability gap の $\approx 74\%$ を SPSA で閉じる。
field-wise specialisation (qpos が深く suppressed、reach_err slope が flat 化) は outcome から自然と出る。

7.3. C3: multi-cell SPSA reveals parameterisation ceiling

F_spsa_fullgrid は、SPSA を 6 cell uniform-random sampling で 100 iteration 回した結果である。




図 6: 上: 6-cell mean outcome trajectory. $K = 0$ grid mean 0.49 m(橙破線)に届かない。下: per-cell min-tip。delay-18 cells で 3-5 cm の改善、delay-0 cells で改善ゼロ。 $K = 0$ からは 19-22 cm($d=18$) / ~ 28 cm($d=0$) 離れたまま。

主要観察:

- delay-18 cells: 3 cells すべてで default reliability より 3-5 cm 改善。 $K = 0$ から 19-22 cm trail。
- delay-0 cells: SPSA はほとんど改善せず、 $K = 0$ から ~ 28 cm trail。
- 全 cell で $K_d^* = 0$ なのに、single global β では reach できない構造的限界。

C3 の核心: SPSA の失敗ではない

single-cell SPSA(C2)は確かに収束した。problem は SPSA loop 自体ではなく、 $\beta \in \mathbb{R}^{10}$ という single-global parameterisation が、cell ごとに異なる innovation geometry を同時に抑えられないこと。

高ノイズ cell で K_f を 0 まで押し下げる $\beta_{0,f}$ を選ぶと、低ノイズ cell では over-suppress、逆も真。一つの β で全 cell の “trust the model” を出すには、reliability の絶対水準を見ず context を見る必要がある。

natural next model:

```
beta_network(  
  sliding window of field-wise innovation statistics  
  (mean, variance, autocorrelation)  
) -> beta in  $R^{10}$ 
```

(sigma, d) を auxiliary input にすることもできるが、生体は noise/delay label を直接観測しないので biological framing では innovation window が primary input。

7.4. C4: task transfer reveals task-dependent rule

ReachRandom(target が episode 毎にランダム抽出)に同じ observer を転移すると、興味深い反転が起きる。

cell	$K = 0$	$K = 1$	default	transferred β	K_{cl}^*
none, d=0	0.670	0.770	0.781	0.768	$K = 0$
none, d=18	0.642	0.647	0.631	0.680	$K = 0.25$
high, d=0	0.670	0.770	0.776	0.768	$K = 0$
high, d=18	0.642	0.639	0.608	0.692	$K = 0.25$
xhigh, d=0	0.670	0.762	0.771	0.759	$K = 0$
xhigh, d=18	0.642	0.627	0.649	0.686	$K = 1$

数値の読み方:

- ReachRandom の K_{cl}^* は $\{0, 0.25, 1\}$ の 3 値を取る multimodal 構造 (Appendix E)。
- delay-18 cells で default reliability が $K = 0$ を勝つ (2 of 3 cells で 1-3 cm)。default rule の $K_f \approx 0.6-0.7$ が偶然 per-cell $K_{cl}^* = 0.25$ に近いため。
- 一方 ReachFixed-trained β は全 delay-18 cell で $K = 0$ を $\sim 4-5$ cm 下回る。source task では $K_{cl}^* = 0$ 一様だったので β が gain を global に下げる方向に学習されており、target task の multimodal K_{cl}^* には合わない。

C4 の核心: rule は task-dependent

correction-gain rule の “正解” は task 構造(= K_{cl}^* geometry)に依存する。

K_{cl}^* が uniform な task では outcome adaptation が closes the gap。

K_{cl}^* が multimodal な task では default reliability の方が逆に競合的(中-高 gain が偶然 multimodal optima に近い)。

testable computational hypothesis: uniform-optimum task で trained agent は multimodal-optimum variant に転移すると性能を落とすはず、context-conditioned rule でない限り。

8. 研究者としての作業手順

8.1. 1 日の作業サイクル

1. 研究問いを1文で書く
2. config を1つだけ変える
3. 実行前に expected outcome と fail condition を書く
4. uv run で実行
5. metrics.csv / summary.json を確認
6. 図表を再生成
7. Logs または exchange に判断を書く
8. commit する

8.2. 実験前チェックリスト

演習 / 作業

- [] env id は意図通りか (myoArmReachFixed-v0 / myoArmReachRandom-v0)
- [] target は paired か、direct-write されているか

- [] downstream policy は true state を見ていないか
- [] policy 名は joint-space feedback controller / endpoint-error sensorimotor policy / behaviour-cloned policy のどれかに整理されているか
- [] action layer (excitation, api_action, activation) が混ざっていないか
- [] delay semantics は過去ノートと一致しているか
- [] run directory に resolved config が保存されるか
- [] random seed / target index / model id が metrics に残るか

8.3. 結果解釈チェックリスト

演習 / 作業

- [] state estimation error と task error を混同していないか
- [] open-loop oracle と closed-loop oracle を分けているか
- [] paired comparison になっているか
- [] single-cell の大きな差を一般化しすぎているか
- [] downstream policy の state coupling を評価しているか
- [] observer sensitivity を reaching performance と混同していないか
- [] negative result を捨てずに設計上の知見として記録しているか

9. よくある失敗と対処

9.1. target が paired でない

myoArmReachRandom-v0 では、単に `env.reset(seed=k)` するだけでは target 再現性が保証されない場合がある。Project 1 では target set を自前で持ち、target site を direct-write する。

```
env.reset()
_inject_target(env, target_set.target_pos[episode_index])
mujoco.mj_forward(model, data)
```

paired target が崩れると、estimator 差ではなく target distribution 差を測ってしまう。

9.2. K と H の混同

correction gain の K と rollout supervision horizon の H を混同しない。

K: sensory prediction-error correction gain, $0 \leq K \leq 1$
H: rollout supervision horizon, H in {1, 4, 8}
d: observation delay steps

9.3. behaviour-cloned policy の open-loop 化(Appendix C 教材)

BC は reaching を改善するが、小規模 demo では平均 trajectory を再生するだけになりやすい。この場合、observer output を入力に入れていても、実質的には state-coupled ではない。Project 1 の main result では joint-PD controller を採用し、BC は Appendix C の oracle-supervised diagnostic に降格してある(observer signal の wash-out を示す methodological caution として残す)。

対処:

- DAgger / closed-loop data aggregation
- target-conditioned policy の明示
- state masking の効果検証
- observer sensitivity metric の導入

9.4. endpoint-error policy を optimal controller と呼ぶ

endpoint-error sensorimotor policy は、estimated tip-to-target error を muscle excitation に写像する task-level policy である。LQR、OFC、Riccati equation は解いていない。Project 1 main では joint-PD のみ

を採用し、endpoint-error policy は Appendix C (oracle-supervised diagnostic) で「joint-PD 以外の state-coupled policy でも同じ qualitative finding が出ること」の確認用として残してある。

対処:

- endpoint-error sensorimotor policy または endpoint-error policy と呼ぶ
- OFC-like, LQR-like, optimal feedback controller と書かない
- absolute reaching と state coupling を分けて評価する
- $K=0$ / $K=1$ / learned で trajectory と action が分かれるかを見る

9.5. SPSSA outcome を training-time と deployed eval で混同する

SPSSA の per-iter outcome は同じ β で s 個 episode 平均しているが、これは training-time の noisy estimate である。fresh deployment では別 seed の独立 episode で測り直す必要がある。

training-time outcome (smoothed last-20-iter mean) vs
deployed eval (final beta, fresh 10 episodes)

Project 1 の C2 では両者を分けて報告している (0.49 m smoothed training vs 0.56 m deployed)。performance claim は deployed eval が headline、smoothed training は convergence evidence。

9.6. oracle なしを “no oracle access” と書く

abstract / intro で “no oracle access” / “without an offline oracle” と書くと、reviewer に “実用システムは当然 oracle 使えないので trivial” と読まれる。実際の non-trivial claim は training 時に per-condition K -sweep oracle ラベルを要求しないこと。

対処:

- “without per-condition oracle labels at training time”
- “rather than oracle-supervised gain learning”
- Appendix C への明示ポイントを併記

10. Project 2 / Project 3 への接続

10.1. Project 1.5: context-conditioned β network

C3 の structural ceiling は、natural な follow-up project として「context-conditioned β 学習器」を要請する。

beta_network:

```
input = sliding window of field-wise innovation statistics
      (mean, variance, autocorrelation; optionally (sigma, d)
      as ablation-only auxiliary)
output = beta = {beta_0_f, beta_1_f} in  $\mathbb{R}^{10}$ 
```

学習 signal は引き続き per-episode reaching outcome を SPSSA / REINFORCE / ES のような black-box optimization で用いる (target K のラベルは依然として使わない)。

設計上の question:

- innovation window 長: episode 全体 vs 直近 50-100 step
- context encoder: small MLP / GRU / Transformer
- network output: β そのもの / β への residual / per-step K_f 直接
- ReachFixed train $\rightarrow$ ReachRandom test の transfer benchmark を pre-commit

これは Project 1 の論文 main scope の外だが、C3 の限界を直接解消する次の研究軸として明示。

10.2. Project 2: Bayesian integration

Project 1 では observation noise を field ごとの Gaussian sigma として扱い、within-trial reliability は innovation 二乗から経験的に推定した。Project 2 では、視覚・固有受容・prediction・prior を別情報源として扱う Bayesian framework に拡張する。

Project 1 との橋渡し:

- ・ Project 1 の reliability $r_{f(t)} = \frac{1}{\varepsilon + v_{f(t)}}$ は noise covariance estimate $\hat{\sigma}_f^2(t) = v_{f(t)}$ の inverse として読める
- ・ Bayesian integration では $w_i \propto \frac{1}{\sigma_i^2}$ で weighting $\rightarrow$ Project 1 logistic を $\sigma(\beta_0 + \beta_1 \log r)$ と書いた $\beta_1 = 1, \beta_0 = 0$ の special case として読める
- ・ Project 2 は modality conflict (visual vs proprioceptive)、prior の bias、posterior の uncertainty を陽に扱う

候補実験:

- ・ visual noise と proprioceptive noise を別々に増やす(現 paper は同一 σ vector で field-wise scale)
- ・ sensory conflict(visual と proprioceptive を意図的に矛盾させる)
- ・ target prior を偏らせる(ReachRandom の target 分布操作)
- ・ endpoint bias / variability を測る
- ・ 各 source の online estimated precision を beta_network の input に追加

10.3. Project 3: cortico-cerebellar loop

Project 1 の residual MLP は Wolpert/Kawato box-level の forward model 近似としては妥当だが、小脳 microcircuit そのものではない。Project 3 では、forward model を以下のような module に分ける。

cortical command

- $\rightarrow$ pontine-like encoder
- $\rightarrow$ cerebellar-like forward model
- $\rightarrow$ thalamic-like relay
- $\rightarrow$ cortical estimator/controller

LTC / CfC は、連続時間・recurrent・入力依存時定数という点で、Project 3 の候補 forward model として自然である。Project 1 の two-layer adaptation(within-trial reliability + across-trial outcome)は、Project 3 の microcircuit module 間でも同じ構造的役割を果たすと想定: cerebellar forward model のシナプス可塑性 = within-trial dynamics、prefrontal / striatal level の outcome-based meta-learning = across-trial.

落とし穴

TNNLS 投稿前に CfC/LTC PoC を始めると、Project 1 の論文主張がぶれやすい。まず Project 1 の投稿を完了し、その後に別ブランチ / 別 phase として Project 1.5(context-conditioned β) $\rightarrow$ Project 2(Bayesian) $\rightarrow$ Project 3(cortico-cerebellar)の順に進める。

11. 演習

11.1. 演習 1: 状態 schema を確認する

```
uv run python -c "from myoarm_fse.envs.factory import make_env; from myoarm_fse.envs.extractors import extract_state; env=make_env('myoArmReachFixed-v0'); env.reset(); s=extract_state(env); print(s.flatten().shape)"
```

期待:

(83,)

11.2. 演習 2: test を通す

```
uv run pytest
uv run pytest -m myosuite
```

default tests と MyoSuite smoke tests の両方を通す。

11.3. 演習 3: 図表を読み解く

F_reliability_default / F_spsa_single / F_spsa_fullgrid を開き、以下を説明せよ。

- ・ F_reliability_default で default reliability が $K=0$ を 23-29 cm 下回る構造的理由は何か(forward model 強度と reliability の関係)
- ・ F_spsa_single の running mean が $K=0$ baseline 0.50 m に到達するのに、deployed eval は 0.56 m に留まる理由は何か(SPSA noise vs eval seed の関係)

- ・ F_spsa_single の bottom panel で qpos の β_0 が一番低く、 β_1 が一番高い意味を解釈せよ(field-wise specialisation)
- ・ F_spsa_fullgrid で multi-cell SPSA が $K = 0$ に届かない理由を構造的に述べよ(single global β の表現限界)
- ・ Appendix C(oracle-supervised)の K_{ol}^* と K_{cl}^* が乖離する条件は何か(forward model multi-step supervision との関係)

11.4. 演習 4: 新しい transfer test を設計する

ReachRandom transfer 以外の transfer 軸(controller 変更、forward model H 変更、noise level 拡張、新しい task variant など)を行う場合、実行前に次を文章で固定せよ。

- ・ 何を replication target とするか
- ・ 何を replication target から外すか
- ・ pass / partial / fail の基準
- ・ target pairing の保証方法
- ・ K_{cl}^* structure(uniform / multimodal)の事前予測
- ・ default reliability vs SPSA-trained β vs $K = 0$ の比較順序
- ・ Appendix に入れる最小図表

11.5. 演習 5: context-conditioned β の prototype を設計する

C3 ceiling を超える next-step model を設計せよ。最低限決めるべきこと:

- ・ β network の入力(sliding window 長、何の statistics か)
- ・ β network の出力構造(β 直接 / residual / per-step K_f)
- ・ 学習 signal(per-episode outcome、step-wise reward など)
- ・ 最適化手法(SPSA / REINFORCE / ES / 微分可能 surrogate)
- ・ ReachFixed $\rightarrow$ ReachRandom transfer の評価設定
- ・ failure mode(over-fit、変動 high など)の事前予想

実装まで進めなくてよい。設計を 1-2 ページにまとめることが演習。

12. 参考資料

12.1. Repository 内

- ・ README.md
- ・ docs/02_InitialImplementationPlan.md
- ・ docs/03_PaperOutline.md
- ・ docs/03_Project1_Foundations.typ
- ・ paper/main.tex
- ・ figures/F1_system_overview.{pdf,png}
- ・ figures/F_reliability_default.{pdf,png}
- ・ figures/F_spsa_single.{pdf,png}
- ・ figures/F_spsa_fullgrid.{pdf,png}
- ・ figures/F2-F7.{pdf,png}(Appendix C oracle-supervised 教材用)
- ・ scripts/make_reframe_figures.py(C1-C3 figure 再生成)
- ・ scripts/diagnose_reliability_observer.py(per-cell K_f dump)
- ・ scripts/train_reliability_adaptive_v2.py(SPSA outer loop)
- ・ src/myoarm_fse/estimators/reliability_adaptive.py

12.2. Obsidian 内

- ・ 20_research/myoarm-fse/_index.md
- ・ 20_research/myoArm新規研究プロジェクト候補_2026-05-09/00_全体研究計画.md
- ・ 20_research/myoArm新規研究プロジェクト候補_2026-05-09/01_Project1_ForwardStateEstimation研究計画.md

12.3. 文献

- Bernstein, N. A. (1967). The Co-ordination and Regulation of Movements.
- Wolpert, D. M., & Ghahramani, Z. (2000). Computational principles of movement neuroscience.
- Kalman, R. E. (1960). A new approach to linear filtering and prediction problems.
- Mehra, R. K. (1970). On the identification of variances and adaptive Kalman filtering(adaptive Kalman = innovation-based covariance estimation の古典).
- Rauch, H. E., Tung, F., & Striebel, C. T. (1965). Maximum likelihood estimates of linear dynamic systems.
- Spall, J. C. (1992). Multivariate Stochastic Approximation Using a Simultaneous Perturbation Gradient Approximation(SPSA の原典)。
- Caggiano et al. (2022). MyoSuite.
- Hasani et al. (2021). Liquid Time-constant Networks.
- Hasani et al. (2022). Closed-form Continuous-time Neural Networks.

13. 最後に

この研究を遂行するうえで最も大切なのは、実験を増やすことではなく、次の4つを分け続けることである。

4つの分離

1. state estimation error と closed-loop task error を分ける。
2. agent-available signals(innovation history, per-episode outcome)と non-agent-available oracle ラベル(per-condition K-sweep の K^*)を分ける。
3. within-trial layer(per-step reliability)と across-trial layer(episode outcome ベースの β 更新)を分ける。
4. SPSA loop convergence(C2 で示した)と parameterisation 表現能力(C3 が拘束されている)を分ける。

この4つを分けて考えれば、Project 1 の実装結果は単なる controller engineering ではなく、forward prediction、innovation-based online reliability、outcome-based across-trial learning の三層構造を持つ生物学的にもっともらしい motor control framework の研究基盤になる。次の自然な拡張は、C3 の structural ceiling を超える context-conditioned β network(Project 1.5)と、それを Bayesian framework に embed する Project 2 である。